

1. Token bu sozning kichikroq matematik bolakka bolinishi. Biz sozni harflarda ko'ra computer sonlar da ko'radi va matrix ko'rinishida bo'ladigan tokens.

Ex: "Artificial" [4 11 3 2 6]  
 Word                      token                      matrix ko'rinishida.

Umumiy xalqda 1ta so'z 0,75 ta tokenga teng. Boshqa tillarda token 1ta so'z 0,5 yoki boshqa miqdor da tokenga teng bo'lishi mumkin. Tokenlarning 3xil holatini ko'rishimiz mumkin:

① Token = Word tokla bilan wordlar

① Love driving 4 tokens

② Tokenlar sozlardan ko'p boladi. Tokens > Words

unbelievable buyurda bitta sozni 3ta token ga bolib olayabdi. Taxlii tushunib train qilish uchun. Natija ham yaxshidi

③ Tokens words den kam boladi. Tokens < Words

United States => [United State] deb 1ta so'z qilib olinadi. Agar alohida

olinsa computer tushunmasdan chalashtirib qolishi mumkin. Ex: United Kingdom.

Tokens words ga qaraganda ancha flexible shunga train qilishga yaxshi.

Inqirodagi holatlar English da yaxshi. non-English tokens bolga junda ko'p tokens talot bolib ketishi mumkin. Tokenlar yaxshi farqi ham so'z hol sub-word (to suffix lori ajratilgan).

söz / va belgilar ham token boladi. Deylik ma'lum miqdor dagi text 1,000,000 token boladi bu boshqa tillorda 2x, 3x yoki 10x bolishi ham mumkin. Bu o'z navbatida Narxga (costga) ta'sir qiladi.

— Yana qo'shimcha tarzda istalgan darajada belgilarni eslab tura oladigan tokens miqdori boladi. Misol unga ajratilgan memoryga 2048 ta token ketse bu ta'xminan 1500 + so'z boshqa tilde 1000 ta yoki 900 ta so'z 2048 ta token bolishi mumkin bu jihatdan English wins.

Kuchli modelga ex: Claude ga 50 pages ni yuklay olga boshqa tillarda 10-15 pages odetda. Buni esa o'zai yuklanga xujjatlarni delete qilishiga sabab boladi.

vaqt — Time masalani bor, English-da 1500 ta so'z 2048 ta tokn bolse rus tilida bu 3500 ta token bolishi mumkin va OLM token-by-token ko'pami uchun boshqa tillarda vaqt ko'p ketadi.

4 xil tokens

- ① Butun so'z 1 toknga teng bolishi.
- ② ~~sub~~ subword tokens bunda so'z oldi va o'ngidan keladigan suffix yani qo'shimchalarni alohida token qilib qilish. Ex. un forgettable bu yerda forget dan mainw bor va (un) va (able) ni ham alohida token qilib olayabadi.

3) Belgilor yoki parchalar bunda  
söz orqaga kirib qolgan notanish  
belgilarni ham 1 ta token qilib  
olib ketadi. Ex. World buyerde  
[W] [O] [rld] buyerde o emas  
0 (not) edi shuning 1 ta token qilib  
oldi. Bu esa natijani yozilgan  
sözlarni ham tushunishga yor-  
dam beradi.

4) Non - word elements.

Bunda belgilar, bosh joy va sonlarni  
ham token qilib oladi.

12 meters ?  $\Rightarrow$  (12) (meter) (S) (?) 4 ta token

LLM model training calculation.

Resurslarimizga qarab harab kitob  
qilib olishimiz kerak parameters,  
memory, compute cost, wall-clock,  
Cost, Efficiency

1) Parameters soni.

$$12 \cdot L \cdot d^2$$

$L \rightarrow$  layers soni

$d$  bu vektor ichidagi sonlar soni  
yani [0.2, -0.6, 7, 8.6, ... 9.7] kabi  
böladi.

GPT-3 da 1 ta vektor ichidagi  
sonlar soni 12288ga bölüb ular  
modelga bir vaqtini o'xide shuacha  
kóp turli xususiyatlarni kodlashga  
imkon beradi.

Ex.  $12 \cdot 6 \cdot 256^2 = 4.7 \text{ mln parameters}$

16B Adam W

$N = \text{parameters row}$   
Date. No.

② Xetira 16B, N

ADAM W bozicha hisob bosak 1 ta parameter 16 bayt talab q'iledi. 16 bayt qayerdan kilyob di.

① Weight (FP32) - 4 bayt

② Gradients (FP32) - 4 bayt

③ Adam m - yonalish  $\rightarrow$  4 bayt

④ Adam v  $\rightarrow$  kattalik  $\rightarrow$  4 bayt.  
Jami 16 bayt.

Ex. 16 bayt  $\times$  4.7 mln parameters = 75.2 mln bayt

$$\frac{75.200000}{1000000.0000} \approx 0.0752 \text{ GB} \approx 75.2 \text{ mb}$$

③ Compute budget  $6 \cdot N \cdot D$

$$6 \cdot 4.7 \text{ mln} \cdot (4.7 \text{ mln} \cdot 20)$$

$$6 \cdot 4.7 \text{ mln} \cdot 94 \text{ mln} = 2.65 \times 10^{15}$$

$N \rightarrow \text{parameters row}$  FLOPs

$D \rightarrow \text{number of tokens}$

④ wall-clock  $\frac{6ND}{\text{GPU peak} \cdot \text{MFU}}$

peak - GPU maximum speed

MFU - GPU samara dorligi.

III  
(Model FLOPs Utilization)

100% GPU samara dorlikka erishmaydi sabaki boshq ishleri ham bo'yaredi!

② memory bandwidth - GPU doim hisob k'ilib qilinmaydi, boshq xetiradan ma'lumat yuklashni "kutib turadi"

① All-reduce - bir nechta GPU parallel ishlar ulas natijalarini bir biri bilan sinxronlashtirish uchun vaqt sarflaydi

② har bir operationni ishga tushirish uchun overhead (qo'shimcha xarajat) bor

③ ham ham - matematik amallar - ~~ba~~ matritsa ko'paytirishidan tashqari (activation functions, normalization) shuninga amallar ham vaqt oladi.

$$\frac{2.65 \times 10^{15}}{10 \text{ TFLOPs} \cdot 0.25} = 1060 \text{ Sekund}$$

$$1060 \text{ S} \approx 17.7 \text{ minut}$$

$2.65 \times 10^{15}$  FLOPs ni peak davrda  $10 \text{ TFLOPs/s}$  tezlikda MFU samara dorriligi 25% bo'lganda 17-18 minut ketadi ekan

⑤ Cost  $\text{time} \cdot \text{GPU} \cdot \text{\$/hour}$

$$0.28 \cdot 1 \cdot 2 \approx 0.48 \text{ \$}$$

Vaqt to'g'ridan to'g'ri pulga aylanadi. Har bir tejalgan foiz bu pul.

## ⑥ Samaradorlik

Bir xil hardware da kamroq pul va vaqt sarflov samaradorlikni oshirish uchun

① MFU oshirish

② BF 16 (FP 16 emas)

③ Activation checkpoint  $\rightarrow \sim 5N$  xotira saqlash

④ Batch/shape tanlash

Trickle off - nimago'dir erishish uchun nimadandir yoz kechish.

BF 16 16 bits egallaydi,  $BF 16 = 3.1 \times 10^2$   
bu dynamic range bunda kam  
kass lekin keng range

Activation & Gradient Check point

Activation? model train vaqtida forward pass hoz bir qatlam orasidan o'tayotganda 2 qatlam oralig'ida-  
gi natijani xotirada saqlab turadi  
va bu saqlangan natijalar  $\rightarrow$  Activations

O'zi saqlash nega kerak? keyinroq backward pass qilganda xatolikka qayti qatlam qancha hissa qo'llaganini bilish kerak misol  
1-qatlam shuncha darajada 2-qatlam shuncha darajada.

kop qatlam kop natija katta joy memory da.

Gradient checkpoint esa yechim.

u natijalar ni saqlamaydi faqat  
biri muhim natijalar ni belgilaydi.

Agar biror noliqni natijasi kerak bolsa uni qaytadan hisob layoli ishtiraga yozib qo'yish o'riniga

## CPU VS GPU

CPU ko'p varifali lekin sekin

GPU esa bitta ishni qili shda zo'r


EX: (matrix calculate) - lekin hamma uzoqda bo'lgan "primat do" bo'lishi kerak.

Datani CPU da yuklab GPU ga ko'chirib kiyin barcha amallarni GPU da gi same version da qilish.


CPU  $\leftrightarrow$  GPU bir biriga ko'chirib yurish katta ism ham bo'ladi sababi ko'p vaqt oladi.

Model va data bir xil device (cuda) da bo'lishi shart


## Architecture



## ④ Pre training Configuration / Execution



## ⇒ Fine-Tuning & Alignment



## ⇒ Deployment

