

Lesson 3.

Date.

No.

① Tokenization → bu matn yoki so'zni tokenga aylantirish jarayoni. Token esa modelga beriladigan kichikrog' matematik blok.

Tokenization turleri → a) so'z = token
ex: Tashkent is the capital
bu yerda 4ta token bo'ladi.

b) Token so'zdan kichik.
I like driving → (I) (like) (drive) (ing)
bu yerda 3ta so'z 4ta token

c) subword - bunda biron so'zning qismalarga ajratib olinishi
orgali tokens so'zdan ko'p bo'ladi
ex: incorrection → (in) (correct) (tion)
1ta so'z 3ta token.

d) Character → bunda belgilar ham 1ta token. ex: Best AI course!
(Best) (AI) (course) (!) bu yerda 3ta so'z 5ta token

e) ~~byte~~ byte orgali tokenlarga bo'lib oladi. ex: Hello
H → 4 e → 2 l → 6 l → 6 o → 8

f) BPE - eng ko'p uchraydigan qismlarni topib bosqichma-bosqich birlashtiradi.

② Bepo training

① Data quality → deduplication → alignment → tokenlar parametrlaridan so'z boravari ko'p bo'lishi kerak → GPU memory yetarlami? → qisqichli kerak bulorni: parametres memory, compute budget, wall-clock

Date. No.

→ Cost va samareдорlikni. Datani CPU da tayyorlab GPU ga kodirishimiz kerak.

③ BPE - yaxshi tarafi tez response, contextni yaxshi tushuna oladi, uzun context qabul qila oladi.

④ Chindillo laib → parametr lar tokenlardan 20 baravar kam bo'lishi.

⑤ Trade off → bu bira norgaga erishish uchun nime dondir o'z kechish. Ex: Vagt yutaman desa GPU ga ko'p tog pul sarf besh kerak Vagt qutib pul yutqoradi yoki tashvish. Model holatida olsoq text uzunligi kam bolsa tez response lekin model aqilli emes.

⑥ Frontier models → bu eng jommo havig, tez response qiledigan, aqilli, uzun context niite oladigan, multifunctional modellor. Ex: GPT 5.6, Sonet 6

⑦ Emergence - bu train davomida dastlab ma'lum vagt davomida natija past bo'lib ma'lum vagtga helqanda birdeniga yaxshi kamib ketishi. Bu hodise kichik modellor da kure til moydis faqat LLM da.

⑧ Alignment → bu insonga zarar bera dige ma'lumot lorni modelimiz berishi oldini olish. Datada Datani manipulation qilgan virda albatto filter qo'gib yomon va zararli gap yoki ko'zet malorni o'tkor masliqi ni idit.

⑨ FLOP - bu ~~bu~~ NN ichidagi bir matematik amal ex: 1.2×7.6 manashu bitta FLOP. FLOPs bor bu mana shunga nechta matematik amal bolsa shulorning jami. Ex. 112 Trillion FLOPs bu LLM uchun miqdor.

⑩ MFU $\rightarrow$ (Model FLOPs Utilization)
Peak $\rightarrow$ GPU 1 sekundda nechta FLOPs ni amalga oshira oladi. Yani 1 sekundda nechta matematik amalni amalga oshira oladi. Ex. my laptop has RTX 3050 GPU 6 GB 10-14 TFLOPs/second

⑪ MFU - GPU, qanday samaradorlikda ishlayotir.

⑫ RLHF $\rightarrow$ user feedback lori, user reward- loqiga qarab next user ga yoki next time shunga qarab javob beradi.

⑬ LM vs LLM

LM - language model bo'lib next word prediction asosida keyingi to'zni predict qiladi. Asosan Auto complete, Grammar check shunga ishlatiladigan qodir.

LLM - large language model ya'ni LM ning advanced darajasi va bunda juda katta data; book, articles, web data lardan foydalanadi. LM ko'pincha LLM multi functional, murakkab hisob kitoblar va qiziq topshiriqlarni ham bajara oladi.

⑭ LLM vs SLM

LLM uchun juda uqta versiyalar
 kerak bir bolai anchagina company-
 lar ham LLM qilishi qiyin.
 SLM va open projectlar uchun qilsak
 bo'lsa digon model ex: bitta kitob bi-
 lan train, shu kitob b-n chat.

③ Bitter lesson $\rightarrow$ Bunda fargatgine GPU
 zor bo'lsa ~~mo~~ zor model qurish n-n
 digon amalga kato chiqqon.

Best model = good architecture $\rightarrow$ massive
 data $\rightarrow$ powerful GPU $\rightarrow$ efficiency $\rightarrow$
 parameter va tokens balance

④ Claude, Chat GPT, Gemenai - bular
 frontair modeller. tababi ulor ancha-
 aqilli, long context ololadi, meaning-
 ful and fast response, video-image
 analysis, summarise,

⑤ Claude, ChatGPT, Gemenai o'laridagi
 aroniy modeller.

Claude $\rightarrow$ Sonet, Haiku, Opus bular
 model fur. Claude o'rinig modelleri
 are Claude 3, 3.5, 3.7, 4, 4.5, 4.6
 4.7, 4.8, 5 veriyalar bor

Chat GPT GPT-3, -3.5, -4, -4.0, 4.1
 -5, -5.1, -5.2, -5.4, -5.5, -5.6, -6.

Gemenai $\rightarrow$ 1.0, 1.5, 2.0, 2.5, 3, 3.5
 3.6, 3.7, 3.8,

⑥ BPE - Bunda eng kop uchray digon
 qismlarni bosqichma bosqich bir loshtiradi
 yani: young $\rightarrow$ younger $\rightarrow$ youngest bu
 yerda young orak tokmni oladi keyin
 yana kelgan -er, -est larini qo'sha
 alohida token qiladi model yaxshi tu

shunaki.

- ⑦ Tokenization bu sozlarni tokenlarga aylantirish va tokenlar sozlonga mos-batan flexible ko'lgani uchun modelga yozishi.
- ⑧ Trainingdan oldin reverslarai hirobleshimiz kerak, data manipulation va CPU da yublab datani GPU ga o'tkrib train qilishimiz kerak.
- ⑨ Parameters lar soni
 $12 \cdot L \cdot d^2$ L - layer
 d - model-dimension
- ⑩ Memory calculating
 $16 \text{ byte} \cdot N \cdot \text{tokens}$
 N - parametrlar soni
 ~~$N \cdot 20$ - tokenlar soni~~
- ⑪ Scaling law - Agar model hajmini oshirib, massive data bilan, ko'prog' compute bo'lsa yaxshi model.
 Yani:
 $\text{large model} \leftrightarrow \text{massive data} \leftrightarrow \text{more compute}$
 $\rightarrow$ yaxshi natija.
- ⑫ SFT $\rightarrow$ bunde savol va to'g'ri javob tarzida o'qitiladi. Yani savolga ideal javob bilan o'qitiladi.

⑮ Transformer muhimli sababi Attention yordamida ~~total~~ tokenlar orasidagi bog'liqlikni o'rganadi, parallel training ni ta'minlaydi.

⑯ BF16, FP16 va FP32 bu yerda aniq farq ularni range da yoni BF16 kamroq da tire, keng range FP32 aniqlik yagoni, ko'proq memory va keng range

FP16 - kam memory lekin tez, range kichik bu esa 0,00 noladan keyin 2 ta sonni olib 0,0001703 bo'lsa 0 ga aylantiriladi.

⑰ Adam W in LLM reason?

katta model training vaqtida tez. Har bir parameter uchun lr (learning rate) moslashirib boradi. Gradient ma'lumatlarini hisobga oladigan parameterni qanday o'zgaritirishni yaxshiroq belgilaydi. Weight decay esa model parameterlari judayam kattalashib ketishi oldini oladi. bu esa overfittingni kamaytiradi.

⑱ Xavier initialization - gradient juda katta (explosion) yoni gradient juda kichik (vanishing) oldini oladi.

⑲ Activation checkpoint → Bu train jarayonida forward pass o'tganda qatlamlar dagi natija (activations) ni saqlamasdan mo'ljallan bit miqdorlarni saqlaydi va backward pass da shu joydan qayta hisoblaydi. Demak train sekinlashadi. GPU memory tejaladi. →

Trade off

Section - B. follow-up questions

① Nega ko'plar tayyor modeldan foydalanibdi. Sababi yangi model qurishga holdan ko'p vaqt ketadi, tayyor modelni esa fine-tuning qilish arzonroq tushadi. Sababi u avval ham trained bo'lgan ma'lum darajada aqilli. Data ham kamroq bo'lsa ham bo'ladi. Natija ham terroq chiqadi yoni holdan ko'tarilishi shart emas.

② Chinchilla va Scaling law farqi
Chinchilla bu fagat model hajmi va train ma'lumotlar o'tanida qanday nisbatda farq bo'lishi kerakligini aytadi (Tokenlar paramester larda 20 baravar ko'p bo'lishi kerak). Scaling law esa parameterlar, tokenlar va compute o'rtasida model qanday o'zgarishini taxmin qilish hisoblaydi.

③ Nega data quantity va quality LLMda bo'lgan AI modellardan ko're muhim.
Sababi LLM model uchun juda katta data bo'lmasa modelimiz moslashib javob berishni bilmay beradi. Quality zarur ligi kerakli, zararli, noto'g'ri javoblarni ma'lumot berish bilsa model sifati yomon chiqadi.

④ Token doim so'z bo'lsa bo'lsin.
Zog. @ Character bunda so'zni belgilovchi qari "Hello! so'zni ~~so'z~~ "Hello" "!"
Undovni ham 1 ta token qilib oladi.

⑤ Word = Token
Hello → 1 ta token

④ BPE Tokenization bunda kóp uchraydigan qismlarni bosqichma bosqich birlashtiradi.
 (un)happy (happy) happy eng kóp uchraydigan qism.

⑤ Parameter larni bilsak uni 16 ga kópaytirib birlashtirish ~~ham~~ xotiraga eýgádimi yo'qmi bilib olamiz.
 Compute budget esa FLOPs sonini o'lashtirib model texnikasini o'tkazish mumkin.
 Vaqt abbatte zarur qanchada tekin qilib bôlishni bilish zarur.
 Pulimizga qarab ish qilganimiz u-4 no'x eng muhimlaridan. Samoradorlik esa qancha vaqt, Pul natija bôlishi eng muhim.

⑥ Katta va kichik model hatti-harakati har xil bôlishi sababi. Katta modellarda odatda attention roli seriluvadi. Kichik modellarda esa roli katta. Attention kichik modellarda kóproq rol o'ynashi sababi u tokenlar orasidagi bog'liqlikni topadi yani qari qari qari bog'liq. Katta modellarda MLP roli katta-
 ligi sababi u murakkab varifalorni ham qilib o'rganadi.

⑦ Har bir FLOP un maximum intellekt yani bu FLOP har birini GPU da harab layoli va GPU densit emas.
 FLOP harab langarda maximum natija olish yaxshi 1000 ta FLOP natijani 60%.
 B modelde 1000 ta FLOP natijani 65%.
 Model B har bir FLOP dan samorali fag-

dalangan.

Date.

No.

⑧ Open AI ning haqiqiy inovat siyohi bu strategik qaror edi. Sababi Transformer arxitekturasini Open AI yoritmoqan. shu arxitektura bilan yaxshi moddini qanday qurishni isbotlagan. GPT-3 175B parameter bilan trained bo'lgan lekin Instruct GPT 1.3B bilan 175B parameter bilan ofral ko'rilgan. Haqiqiy inovatiga Faqat modelni aqilli qilish emas, uni inson kohlagandek oson, qulay, to'g'ri ishlatish. Bu bilan ulor RLEF va alignment ancha foydali ekani biladi.

⑨ Chinchilla laus bo'g'icha GPT-3 "under-trained" yetarlicha o'qitilmagan sababi 175B parameter va 300B token b-n o'qitgan bu esa tokenlar parameterlarday 2 baravar ham ko'pmashligini ko'rsatadi.

⑩ BPE nega asral?

a) Character levelda 1ta harf 1ta token sequence usun bo'lib va token usun model ko'p tokenni ko'p qayta idilaydi.

b) Word-level bunda usun yoki kam ichraydigan to'rlorni bo'la olmaydi natijada qiyualadi yoki unknown token deb oladi.

c) BPE esa to'rlorni ultrak li qismlarga bo'ladi.

(sleeping)

11) FP 16 roddo aylash range kam
 oladi. BF 16 k6p oladi.
 $1e-8 \rightarrow 0,00000001$ bunday kichik
 qiymatni toqalay olmaydi va natija-
 da 0 (holga) aylanib ketadi.
 BF 16 esa $0,00000001$ ni xusolati shun-
 day toqalay oladi.

Exponent degan nomda FP 16 $\rightarrow 5$ bit
 BF 16 esa $\rightarrow 8$ -bit

12) GND

bunda 4 backward pass va 2 forward
 pass. N - parameters soni, D - esa
 chinchilla lar b6yicha N. 20 dan
 kelgadi.

13) MFU to'liqga yetib olishining
 sababi GPU FLOPs calculate qilish-
 dan fozlagari GPU ~~ot~~ lar qismlari
 ushuncha yuklashini kutib turadi.
 All-reduce yoni parallel ishlagan
 GPU lar bir biri b-u natijalarni
 sinxron lashtirishi kerak. Normaliza-
 tion va activation functions ham yet
 oladi.

14) Adam W da 1ta parameter u-n taxminan
 16 bayt kerak.

Weight uchun 4 bayt Model o'zgarish parametrlari
 Gradient u-n 4 bayt W ni qayri tomonga o'zgarishini
 m u-n 4 bayt Gradient moving average
 v u-n 4 bayt Gradient square moving average

15) Out of memory (OOM crash) oldini olish
 uchun mana shu yuqoridagi memory
 accounting qilinadi.

Ⓐ batch-size kamaytirish.

Ⓑ Gradient check point

Ⓒ kamroq layer berish

⑥ MFU oshirish bu GPU hisoblash vaqtida samaradorligini oshirish GPU imkoniyatiga qarab batch-size oshirish, data loadingni tezlashtirish Precision bilan ~~h~~ harxni kamaytirish FP32 emas BF16 dan foydalanish va EX: FP32 10 milliard parameterli model weight lori uchun 40 GB BF16 da esa 20 GB 2x kam.

MFU + Precision birga: MFU samaradorligi oshirish va precision ham to'g'ri tanlab GPU da ham xotira oshirish saqlash qisqaradi ~~sa~~ pul ham tejaladi.

⑦ Kichik model natijaga qarab katta model natijasi ham shunga bo'ladi deyish katta. Katta modelda yangi qobiliyatlar qo'shiladi birdan yoki emergence lekin kichik modelda emas.

⑧ RLHF bunda reward muhim sababi reward berilish o'shandan o'rganadi yoki qaygi javob yaxshi ekani ni o'rganib yana shunga javob beradi. AI model qilingand bir nechta javoblar trained bo'lgan bo'ladi va odamlar qaygi yaxshirog' ekani ni tanlaydi va tanlangan javob bo'yicha model trained bo'ladi. Yangi trained model javoblariga reward beradi eng yaxshi answerga misal uch: 0.8 eng yomoniga 0.2.

⑨ SFT bu supervised fine-tuning bunda odam yoki user o'zi eng to'g'ri javobni beradi va shundan o'rganadi. Model inson javobini ko'rib to'g'ri javobni sample qilib shunga o'xshatib javob berishni o'rgatib train qiladi. Umumiy savolga qanday javob berishni ~~sa~~ train qiladi.

SFT RLHF o'qatpatgan narsani
o'qata olmaydi. gani 2ta yoki 3ta
javobdan qaysi biri ularga ma'qul
ekani o'qata olmaydi. S
SFT - how to answer to user
RLHF - which answer is better for user.

(20) Pretraining va foydali assistant orasi-
dagi farq bu Pretraining paytida
model asosan keyingi to'zni yoki
tokenni predict qilishni o'rganadi
bunda model uzun lekin foydalanish
natijasi, ma'noli javob berishi
mumkin, javob raqfizi bo'lmadigi
ham mumkin. foydalanuvchi to'ra-
gan ushbadan boshqa narsani answer
qilishi mumkin. Useful assistant
qilish uchun Pretraining → SFT →
→ RLHF qo'shish kerak.

(21) Common crawl dagi ham materiallar
asosiy muammoni bulor reklama va
spamlor, duplicated text lor, zararli
toxic ma'lumatlor bulorda filter
qilish kerak.
Quality filter, Safety filter, deduplication
cleaning, language filter. bulorni
qilgandan keyin dataset tayyor bo'la-
di.

(22) barcha Modelni katta lashtirishdan ko'ra
data sifatini 2x yaxshi yaxshilash
foydali sababi foydalanish kerakli
matnlar ma'noli, natijasi javobga
sabab va modelni katta lashtirish ham
f. boshqar model ma'noli javob beradi.

(23) CPU va GPU o'rtasida tensor ko'chirishida avvalo ~~ma~~ data ni CPU da yuklab tayyorlab GPU ga ko'chirish kerak. Bunda bir xil device bo'lishi kerak, ya'ni Model GPU da bo'lsa input tensor ham GPU da bo'lishi kerak GPU xotirasi (VRAM) yetarliligi yo'q bo'lishi kerak. Har bir iterationda CPU $\leftrightarrow$ GPU qilmaslik kerak. Natijari bisha xato beradi misol model GPU da lekin input tensor (x) CPU da. Sekinlashish qachon ro'y beradi. CPU $\rightarrow$ GPU $\rightarrow$ calculate $\rightarrow$ GPU $\rightarrow$ CPU. Bunda hiroblashga emas ma'lumot kiritishga ko'p vaqt ketib qoladi. Model va input tensor GPU (VRAM) ga sig'masa Out of memory (OOM) crash bo'ladi.

(24) Check point saqlashda model ham optimizer ham saqlanishi kerak. Tababi keyingi trainda avvalgi holatni bilishi kerak. Misol u-n 1-layerda hisob kitobdan keyin faqat model saqlandi. Adam W bilan 1- ~~hisob~~ hisoblanib saqlanmadi. 2-layerda ham yana beshidan train bo'lib qo'llaniladi. Loss kamayishi kerak.

(25) Agar katta modelga narx va vaqtning nisbatlarini 70 B 1.21 B dan $\approx$ 58 marta katta ekan. Misol uchun 1.21 B parameterli kichik model uchun 1 kun 24 soat vaqt yetgan bo'lsa 70 B uchun 58 kun. Narx: Agar 1 kunda ~~58 kun~~ train u-n 50 dollar ketse 58 kunda 2900 dollar ketadi. Lekin Tokens soni o'zgarib FLOP, ham o'zgaradi tokens o'zgarishi shart chinchillo qonuni bo'yicha. 70 B parameterli modelda GPU ko'payishi kerak 1.21 B parameterli model

siḡḡan GPU ga ḡḡḡaydi.