Lesson 5.

Block foundations

Layer bu ~~no~~ input ma'lumotlarni matematik amallar bilan qayta ishlab outputga yoki keyingi qatlamga ōtkazadigan bosqich. Layerda parameterlar yani weight va bais yordamida hisoblaydi.

LLM da NN 2ta qismdan tashkil topgan
Attention layer bu tokenlar bir biriga qanday bog'langanini hisoblaydi.
Feed-Forward Network layer esa har bir token yani sōz alohida ishlay olishini taminlaydi.
Attention layerda ōtgan mavzuda aytganimizdek pairwise relationship qiladi yani 1ta token boshqalari bilan qanday bog'liqliligi bor FFN esa har bir token alohida ma'no berishi uchun alohida ishlaydi. Attentionda contex hamma sōzga qarab chiqar edi FFN esa 1ta token vectorigagina qaraydi. Attention layer contex gramatikasi, sōzlarning ōrnini ōrgatsa FFN esa aniq faktlar, mantiqiy fikrlash qoliplarini ōrgatadi.

NN layer 2xil Seria yoki parallel rivojlanadi.
Serial bunda sal sekinroq bōladi jarayon sababi Attention layerdan keyin chiqqan output FFNga kiradi. Parallelda esa 1 ma'lumot bōlinib yarmi Attention layerga yarmi FFN ga kiradi. Serialda Attentiondan chiqishini kutib vaqt yutqazamiz va GPU ham kutib turib xotirani ishlatmasdan yutqazamiz. FFN da esa GPU Tensor ~~yadrosida~~ yadrolarida bitta ulkan operatsiyaga birlashtiriladi.

Serialda kod yozish va tushunish oson lekin Parallelda compute saving bōladi. Train vaqti ham sezilarli kamayadi. Serial kichik eksperimentlar uchun yaxshi katta modellarda train juda qimmatga tushadi sekin ishlaydi. Parallel esa Sanoat Standarti.

Normalization → avval ham kōrganimizdek NN ichidagi sonlarni minimallashtirish Scalingga ōxshash.

Normalization 2ga bōlinadi.

Layer Normalization va RMSNormalization

Layer Norm Mean va Variance dan foydalanadi. Mean shu qōshib bōlish Variance eslasak u ōrtacha qiymatdan qanchalik og'ganini hisoblaydi.

Ex: [2, 4, 6] vektor bor bōlgan

Variance hisoblasak mean ④

$$\frac{(2-4)^2+(4-4)^2+(6-4)^2}{3} = \frac{8}{3} = 2.6$$ Variance 2.6

Agar mean 4 bōlsa variance 0 bōlsa bunda barcha qiymatlar bir xil lekin variance katta bōlsa qiymatlar ōrtacha qiymatdan kengroq tarqalgan bōladi. Mean va Varianceni hisoblagani u-n kop kotira oladi. va hisoblash ham murakkabroq.

RMS Norm zamonaviy usul GPU da mean va variance hisoblamagani u-n kam hisob kitob qiladi. kam hisob kitob kam vaqt frontier modellarda samara beradi.

bunda [2, 4, 6] vector bōlsa

$$\frac{2^2+4^2+6^2}{3} = \frac{56}{3} \quad \sqrt{\frac{56}{3}} = 4,32$$ Endi

$$\frac{2}{4.32} \approx 0.46 \quad \frac{4}{4.32} \approx 0.92 \quad \frac{6}{4.32} \approx 1.38$$

New: [0.46, 0.92, 1.38] ← Old [2, 4, 6]

RMS Norm ancha tez, resurs tejaydi. zamonaviy usul.

Activation Functions

Avvalgilarni eslasak modelga asosiy vazifasi non-linearity qoʻshar edi. Shuningdek Activation function reasoning yani model murakab complex maʼlumotlarni bera olishi masalalarni yecha olishi va shunday complex task larni qilishi

ReLU noldan katta musbatlarni olar edi. Negative neyronlarni tashlab yuborgani uchun LLM da ishlatmaymiz

GELU ilk transformerlarda ishlatilingan

Hozirda sanoat standarti Swish GLU tez, aqlli, maqsadli tizim.

GEGLU ham SwiGLU b-n deyarli bir xil faqat sekinroq.

Vocablary and tokenization BPE

Tokenization avval batafsil koʻrgan edik.

Ex: Vatan parvar lik → tokenizationda ID's

vatan → 44 parvar → 76 lik → 123

Vocabularyga yigʻayotib 44, 76, 123 boʻlsa Vatanparvarlik soʻzi yasaladi va vatan soʻzini 44 ID bilan izlab topib ifodalaydi faqat user koʻziga vatan boʻlib koʻrinadi.

Pre-Normalization vs Post-Normalization

Pre-Norm normalization qilib keyin Attention ~~ga~~ va FFN ga beradi yaxshi tarafi hisoblashda sonlar kichroq, ch tartiblangan sonlar modelni chuqurroq oʻqitishga yaxshi.

Post-Norm esa Attention/FFN da hisoblab

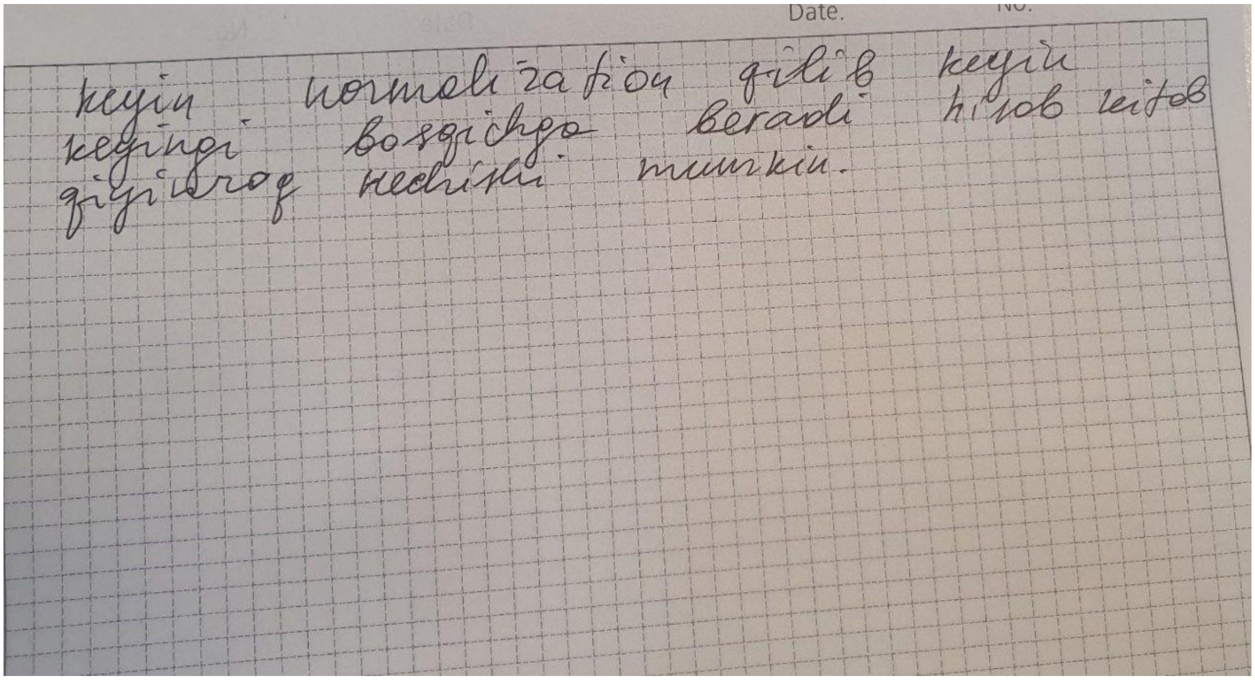

Date. No.

keyin normalization qilib keyin
keyingi bosqichga beradi hisob kitob
qiyinroq kechishi mumkin.