Lesson 6 (oraliq)

1. LLM da Layer bu NN ni tashkil qiluvchi asosiy qism va layerda matematik hisob kitob lar w dan foydalanib yani parametersdan foydalanib ōzidan keyingi layerga yoki outputga natijani uzatadigan qism.

2. Tokenization bu words ning raqamli ID larga convert bōlishi va shu raqamlarni bir lashtirib sōz yasash vocabulary bōladi.

3. Tokenization turlari
a) character level bunda har bir belgi ham 1 ta token va har bir harfni 1 ta token qilib oladi
b) BPE bunda sōzlarni kerakli joyini ma'noli qilib bōladi. (Vatan)(parvar)(lik) vatanni asos qilib qolgan narsalarni qōshib yaxshi ōrgana oladi.
c) word level bunda 1 ta sōzni 1 ta token qilib olib ketadi.

4. Layer 2 ta sub layer Attention layer va Feed-forward layerdan tashkil topgan

5. Attention layer context dagi tokenlarni boshqa tokenlar bilan aloqasini ōrganib context ni tushunishga yordam beradi (Pairwise relationship) FFN feed-forward Network esa har bir token mustaqil ma'no berishini ta'minlaydi.

6. Activation function bu avvalo modelga non-linearity qōshadi. Non-linearity modelni ōrganishini

complex qiladi va reasoningga sabab bōladi.

ReLU buni LLM da ishlatmaymiz sababi u negative neyronlarni nolga tenglab tashlab yuboradi.

SwishGLU bor sano'at standarti eng mos turi

GELU ham SwishGLU ga deyarli ōxshash lekin sekinroq

follow up question answers

1. LLM architecture explaining →

Cleaned data bor bōlsin → Tokenlarga ōtkazib olamiz va → Embedding bilan raqamli vektorlarga ōtkazamiz keyin layerda ular hisob kitob uchun osonlashadi va layerda aynan attention layerda 1 ta tokenning boshqa tokens bilan aloqalarini kōradi va boshqa tokenlar bilan qanday bog'langanligiga qarab context ni tushunishga harakat qiladi. keyin yoki parallel FFN feed-forward Network da yani MLP da 1ta token mustaqil ma'no bera olishini taminlaydi. keyin boshqa bosqichlar keladi yani SFT bu bilan biz savol va savolga best answer berib ōrgatamiz va RLHF bilan esa unga qaysi javoblar users uchun yaxshi qanday javoblar yoqmasligini ōrgatamiz. keyinroq output javob chiqishi u-n Ex: Softmax activationdan foydalanib output chiqarib output unembedding qilamiz va user tushunarli oladi shunda. Deploy va monitoring keyingi bosqichlar.

2, Encoding vs Embedding bunda Encoding aniq belgilab qōyilgan qoidalar asosida kategori caloldan numericalga ōtkazadi. Encodingdan keyingi holatda Hello → 1 bōlsa kompyuter Hello degan narsani 1 deb olganini aslida Hello salom ekanini umuman tushunmaydi. Embeddingda esa Helloni → token → Embedding qilib olsa [1.2, 2.3, 4.5, -7.6, 0.6 ..] ma'no bor.

3, Trade off bu biror narsaga erishish u-n biror narsadan voz kechish, yani agar tez train u-n koproq GPU olamiz desak vaqtdan yutamiz kōp pul ketadi. Qachonki balance bōlsa ~~da~~ trade off bōladi:

4. Model tōxtab qolishi: OOM bōlsa yani out of memory bōlsa, Exploding Gradient bōlsa yani ~~loss~~ learning rate juda katta bersak loss juda ōynab ketadi, Data tōgri Tokenization va Embedding bōlmasa. Model yoki data biri CPU biri GPU da bōlib qolsa.

.Attention bu matematik amallar mexanizmi layeri esa shu jarayonlar ketadigan joy

6, Serial va Parallel bunda Serialni ishlatsak GPU bir qismi kutib qoladi vaqtdan ham yutqazamiz, ~~Sar~~ Attention layerdagi output FFN (MLP) ga kirib yana vaqt oladi. Parallelda esa data 2 ga bōlinib 1 qismi Attention layerga 1 qismi FFN ga kiradi GPU tōliq ishlaydi. Serialda kod yozish va tushunish oson Parallelda qiyin lekin tez va resurs tejaydi.

7. RMSE nega yaxshi sababi undagi matematik hisob kitoblar Mean, Variance ga qaraganda kam. Kam hisob kitob kam memory. Hozirda Sanoat Standarti.

8. ReLU eskirgan deyishimiz xatoroq chunki u LLM u-n mos emas boshqa larida mos bo'lishi mumkin. LLM da u negative neyronsni tashlab yuborgani u-n contextni to'liq tushuna olmaydi.

9. MHA va MQA. bu yerda multi-head attention har bir head har bir K va V u-n combinatsiyasi bor shu sababli sekinroq va ko'p memory. Multi Quary-head esa joy kam oladi lekin bir nechta Multi Query head 1 ta k va V bilan combinatsiya qilib contextni yaxshi tushuna olmasligi mumkin.

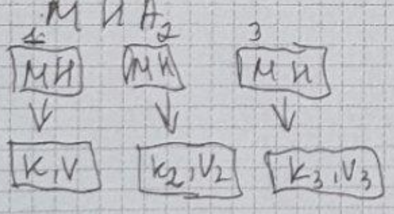
MHA
1
2
3
MH
MH
MH
K,V
K2,V2
K3,V3

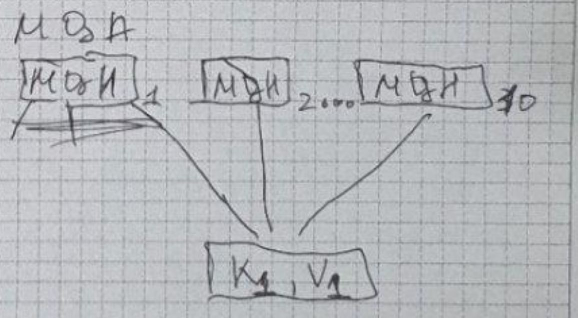
MQA
MQH 1
MQH 2....
MQH 10
K1, V1

10.

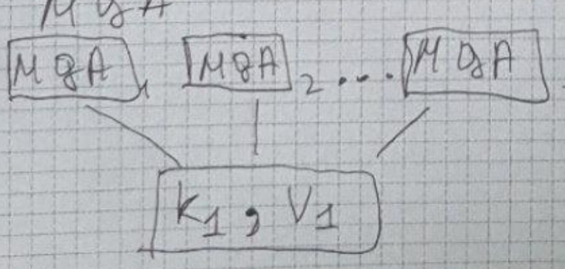
MQA
MQA 1
MQA 2...
MQA 10
K1, V1

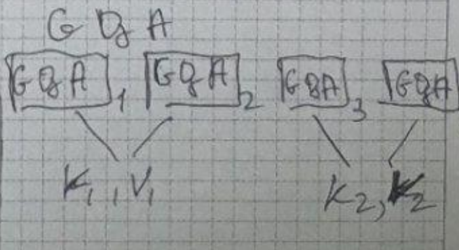
GQA
GQA 1
GQA 2
GQA 3
GQA 4
K1,V1
K2,V2

11. Distributive Representation bu 1ta token yani sōzning xususiyatlarini raqamli vektordagi raqamlarga taqsimlab tashlashi.

Ex: Hello → [0,1, 0,7, 0,9, 7,1, 6,9, ... -2,3, 0,2]
vector ichida 120 ta son bor deylik lekin Helloning 12ta xususiyati yoq 4 yoki beshtadir lekin shu xususiyatlarini 120 ta vektor ichidagi sonlarga taqsimlab yuborishi.

12. Reasoning bu model savolni tahlil qilishi uni tushunishi va ma'noli tōgri bosqichma- bosqich javob berishi.
Ex: $(a+b)^2$ deb savol bersam va qisqa kōpaytirish formulasi ekanini tushunsa keyin qavsdan birinchi b^2 ni ochivormasdan $a^2+2ab+b^2$ deb mantiqiy tōgri ketma- ketlikda va tōgri javob bersa mana shu ham reasoning.