Lesson 10. Date. No.

LLM bu hozirda ishlatilgan AI turlari bilan bog'lanib ketgan soha desak bo'ladi. Hozirda CV sohasini Machine learning o'zi bo'ladimi hammasi baribir LLM dan ishini osonlashtirish qulaylashtirish uchun foydalanmoqda. LLM har kun rivojlanib hali yaratilganiga yoki o'ylab topilganiga ko'p bo'lmagan usul yoki metodlar ishlatishga ulgurayabdi. Ex: Layerda Attention va MLP (FFN) ni ishlagan bo'lsa ham parallel yo'lini tanlayabdi. Va buncha misollar har bir qismda topishimiz mumkin.

"GPT 2" va "SmolLM2-360M"

GPT2 -> Embedding (50257, 768) wte
(1024, 768) wpe

SmolLM2-360M boshqacharoq'ini negadir wte va wpe larni qayta usul bilan qilganini ko'rsatmayabdi. GPT va Llama modal farqli shunga tal boshqacha bo'lishi ham mumkin.

GPT2 eski shunga dropout ishlatilingan SmolLM2-360M esa nisbatan yangi dropout = 0.0 turibdi. GPT2 LayerNorm dan foydalangan va Attention va MLP dan oldin foydalangan. ~~Smol~~ LayerNorm eski usul. Pre-Norm qilgani yaxshiroq lekin LayerNorm ko'p hisob kitob va ko'p vaqt GPU memory ham ko'proq ketadi. SmolLM2-360M esa Post-Norm qilgan Attention va MLP dan keyin lekin RSMSNorm bilan qilgan. GPT2 12 layer small version bu SmolLM2-360M esa 32 layer. GPT2 Attentiondan SmolLM2 esa self-Attentiondan foydalangan. yani GPT2 cross-Attention desak to'g'riroq ekan foydalanganini. GPT2 eskiligi uchun QKV yo'q SmolLM2-360M esa bor va MHA, GQA, MQA qay biridan foydalanganini

Date. No.

ni topolmadim. GQA bu bir xamaroli, Llama modelda vector ichidagi sonlar 960 GPT2 da esa 768. GPT2 ta New GELU Activation ishlatilgan Llama modl. da esa SiLU Activation ishlatilgan. Q,K,V GPT2 da yo'q degani umuman yo'q emas 3 tani birlashtirib ~~2054~~ 2304 qilib umumiy qilib olgan.

EOS - bu end of Sequence bo'lib yani model response qilganda javob yakunlandi deb hisoblaganda max-tokens ga yetmasa ham to'xtatishi.
Maximum tokens user yoki API tomonidan cheklab qo'yilgan bo'ladi. Max tokensga yetganda javob to'liq bo'lmasa ham to'xtaydi.

Trades off - bu biror narsa yoki biror tarafni yaxshilash evaziga boshqa narsa yoki tarafdan yutqazishi yoki voz kechishi.
LLM - aqlli, ko'p xotira, ko'p pul lekin murakkab tasklarni yaxshi bajaradi
SLM esa tez, kam xarajat, kam memory lekin murakkab tasklar u-n yaxshi emas.

Name	Date modified	Type	Size
config	10/23/2026 5:26 PM	JSON Source File	1 KB
merges	10/23/2026 5:30 PM	텍스트 문서	456 KB
model.safetensors	10/23/2026 5:27 PM	SAFETENSORS File	706,714 KB
special_tokens_map	10/23/2026 5:30 PM	JSON Source File	1 KB
tokenizer	10/23/2026 5:30 PM	JSON Source File	2,056 KB
tokenizer_config	10/23/2026 5:30 PM	JSON Source File	4 KB
vocab	10/23/2026 5:30 PM	JSON Source File	782 KB