Lesson 1

LLM 2-oyimizda o'zimizning modelimiz
i quramiz. Buning uchun albatta
data kerak va biz u datani qa-
yerdan qancha miqdorda va qan-
day olishlikni mana shu oyda
o'rganamiz. Shuningdek bu oydagi
LLM model datamiz boshqa oydag-
gi modellarimiz datalaridan farqli
bo'ladi. Misol uchun Tabular datamiz
missing values bo'lsa bu ~~mo~~ muammoni
bartaraf etish osonroq ~~bo~~ va faqat
bir turdagi datalarni beramiz yoki
CV modelda ham faqat rasm yoki
video beramiz. Lekin LLM o'zga
farqli holi datamizda rasm
yoki table shunaqa narsalar
bo'lsa, boshqa tildagi texts
aralashgan bo'lsa qanday qila-
miz. aniq. bilmayman. mana shu

o'rgansak kerak. Qiziq ham rasm
em table bor data bo'lib qolso
anday manipulation qilamiz.
Resource bizda yetarli emasligi
uchun biz qurmoqchi bo'lgan
model GPT, Claude kabi
Frontier Models ga o'xshab javob
bermaydi. SLM modelimiz ular
b-n raqobatlasha olmaydi lekin
o'zimiz qurib ko'rsak bu baribir
juda muhim tajriba va bilim
bo'ladi.

Endi mana shu LLM imizni qur-
shimiz uch GPU kerak va buni
google colab dan foydalansak bo'la-
di. GPU dan tashqari TPU ham
foydalanish imkoniyati bor,
lekin biz juda katta Model qur-
maymiz GPU yetarli. Google
colab ni VS. code ga ulab ishlat
sak bo'ladi.

Bunda VS code shunchaki ekran ya'ni User Interface qilardik shunga ōx-shab va google serverda run bō-ladi kodlarimiz.

GPU vs GPU vs TPU

GPU Nvidia tomonidan ishlab chiqarila-di, custom modellar uchun yaxshi va standart PyTorch code Syntaxi shundan foydalanadi. Localda ham web-servingda ham foydalansa bōladi yani run. Debugging vaqtida oson sabab qadamma-qadam yani satma-ket. Real dunyoda start-up lar uchun va 1B parameterga-cha train, fine-tuning qila olamiz local computerimizda EX: Google colab ulab qilamiz. TPU esa TensorFlow code syntax, multi-billion parameterli modellar train uchun ya faqat Google cloud Platformda run qila olamiz. Debugging uchun murakkab. va TPU da frontier models trained

bolgan.

CPU vs GPU vs TPU

CPUda active bolmasak 90 minutda chiqib ketadi. 12.7 GB memory beradi va tekin. GPU esa 30 minut inactivate dan keyin execute boladi. 15 GB beradi kunlik berilgan creditsdan foydalaniladi. TPU esa 15 min inactive bolsak execute boladi 47 GB memory lekin consumption juda yuqori. Kcholosiki ham 12 hour run qilsak boladi.

Pre-training vs Post-training

Pre-training bu biz qurayotgan modelni bergan datamiz bilan "next token prediction" ni amalga oshirib beradi yani bunda modelga bilim. bersa. Post.-trainingda model

murakkab tasklarni bajarishga o'zga-
tiliradi. Ya'ni bu oyimizda biz
modelimizni qurish u-n data
collecting, data manipulation,
tokenization, Embedding va
transformer ichida Attention va
FFN (MLP) parallel ketib train
bo'lib output chiqarib bera
oladi bekin ~~gi[illegible]~~ aytsak
bo'ladi bizni model xolatida
faqat predict next token gilla
oladi.

LLM dataset to'plash yoki topish
uchun Hugging face, Common Crawl
yoki web-sites, Wikipedia kabilardan
yoki Github dan olsak bo'ladi
va bazi tozalash ishlari shart.

follow-up questions

1. Bizni kelotimizda CPU, GPU va TPU ozni va ahamiyati.
2. Training token budget qanday hisoblaymiz
3. Tensor flow vs PyTorch
4. CUDA siz PyTorch va Tensorflow foydalansa boladimi?
5. Pre va Post training qilish bilan modelni qanday qobilyatlarini ostiramiz?
6. Faqat Pre-training yoki Post-training qilsak nima boladi.
7. BPE yangi yoki kam uchraydigan sozlarni qanday ifodalaydi?
8. Distributed representation nima?
9. Deep learningda GPU nega tez bolishi kerak deymiz qanday tez boladi.
10. BPE sozni ex: learning ikkitaga bolib saqlab olayabdi bu usul n-n token kopayib compute ham kop. ketmaydimi?