Lesson 3

Basic questions

1. Pre-training bu biz bergan data bilan "next token predection" qilodi yani modelga bilim beradi. Post-training esa model murakkab tasklarni amalga oshirish u-n o'rgatadi. Pre-training ko'p data talab qiladi sababi modelni aqilli qilsagina ulgir murakkab tasklarni o'rgatish mantiqli bo'ladi. Emergence ham Pre-trainingda yuz beradi. avvaldan ma'lum Emergence kam data b-n yuz bermay di.

2. Common-Crawldagi data ni to'g'ridan to'g'ri ishlata olmay miz sababi data juda sifati past bo'ladi. takroriy. ma'lumotlar. ko'p

toxic va harmful informations bo'lishi m-n. factual correction bo'lmasligi mumkin.

(3) fine-web bu Common Crawldagi data olinib tozalanib upload qilingan joy. data quality Common Crawl dan yaxshi. Web data upload qilinadi odatda.

(4) LLM loyihamizda .gitignore file ichida github ga push qilinmaydigan files ro'yxati bo'lishi kerak. Sababi biz large files ni git repo ga push qila olmaymiz memory yetmaydi. API key va tokens repoga push qilinmasligi kerak shuningdek.

(5) Agar API key yoki token github

ga push qilinsa tasodifan bilmasdan menimcha avvalo repo ni private qilish kerak tez bo'ladi va keyin API key va token ~~[illegible]~~ push bo'lmasligi u-n .gitignor ichiga qo'shish kerak.

⑥ Pre-training CPU bilan bo'lmaydi sababi u GPU ga qaraganda juda ko'p vaqt oladi. GPU Parallel hisoblay oladi va bir turdagi operations ni juda tez qiladi math calculate ni juda tez qiladi, CPU ketma ket hisoblaydi. VS code + Google colab bu GPU yo'q laptoplar ham LLM yoki CV shunaqa GPU talab qiladigan ishlarni qila olish u-n kerak ∫a bu b-n ~~ko'proq~~. GPU olib yanada tezlatish m-m agar zo'riqish yoki pul. ~~[illegible]~~

⑦ Data mixture muhim sababi modelimiz agar 1 ta data b-n qilinsa u faqat shu turdagi data ni ko'rgani u-n unga prompt bera olmaymiz. U b-n chat qila olmaymiz va u bizga berayotgan response ni tushuntirib bera olmaydi.

⑧ Deduplication bu ma'lumotlar yoki textlarning ikkilanib yani takrorlanib qolishi ularni data dan ololiw korishimiz sababi u biz ni resource mizni tejaydi deduplication bolgan text yoki ma'lumot toralansa.

⑨ Katta data yaxshi model anglatmasligi sababi juda kop. data quality, model architecture,

tokens parameters b-n nisbati. Katta dataga mos resource bo'lishi. Yana u katta datamiz to'g'rimi yo'lgon yoki ma'nosiz emasmi? shu sabablar.

⑨ ⑩ MIT license boshqa b-n u dasturi share qilish, o'zgartirish kiritish, va biznes maqsadida foydalanishga ruxsat degani bilan baribir egasidan ruxsat olish kerak. bu etika jihatdan juda zarur.

Intermediate questions

① Coding u-n Stack Vs yaxshi data olish u-n. 50% Coding u-n data. 30 foiz chat va code ni userga tushuntirish u-n data. 10% matematic gani

Science go oid 5a 10 % li Wikipedia ma' lumotlari.

(12) Compute garfidan oldingi corpus sifati ~~bo~~ data u-n garalsa web data 40-50 % dan oshmasligi, articles esa taxminan 10 foiz tashkil qilsa yaxshi, books esa 90 %, educational data esa 15 %, reference data ham 5 %, code data 10 %.

(13) Qattiq filter data hajmini kamaytirsa ham u juda zarur trade-off bilan yani balance ulash u-n avvalda ishonchli joylari yaxshiroq data olgan yaxshi yani Common Crawl emas fine-Web dan olsa data hajmi sezirali. ~~kamaymaydi~~.

(14) Web corpus da benchmark leakage ni aniqlash uchun albata coding bilan uni ko'rish kerak yani agar biz test qilib ko'rmoqchi bo'lgan savolimizni Pre-training da model ko'rgan ko'rmagani.

(15) Exact va fuzzy dedup qachon qay biri? Exact bu corpus ichidan test qilmoqchi bo'lgan savolimizni qidiramiz. fuzzy esa faqatgina test savolni emas o'xshash matnlarni ham topadi.

(16) Data 80 foiz ingliz tilida users o'zbek tilida 1-navbatda o'zbekcha data qo'shamiz agar yetarli data bo'lmasa uni o'zbek tiliga tarjima qilib train qilsak bo'lmaydimi (meni fikrim) shuni qilsa ham foyda berishi kerak menimcha.

2- yōli undersamplinggo öxshab English dagi datani kamaytirish. bu yaxshi usul emas lekin 1ta yōl. Shulardan boshqa fikr kelmadi.

(17) faqat sifatli matn emas safety va PII filtering ham muhim sababi foydalanishga ruxsat etilmagan informatsiya yoki privacy ma'lumotlar kirib qolmasligi kerak data ichiga.

PII - personal Identifiable information bularni filtri juda muhim odamning ismi, emaili, nagomi, uy adressi bank kartalari shunaq narsalarni aniqlab datadan chiqarib tashlash muhim. ~~Overfitting~~ Overfiltering havfi u kerakli, foydali, xalqni model u-n kerakli ma'lumot yoki textni datadan chiqarib tashla-

shu. bularni aniqlashda o'zimiz qoida ishlab chiqib remove qilsak bo'ladi, false positive va false negative ko'rsatkichlarini hisoblab remove qilsa bo'ladi.

Git ignore xavfsizlik mexanizmi repo ga maxfiy fayllarni adashib tasodifan qo'shib yuborishdan asrashga harakat qiladi.

(19) Pre-training da data unsupervised bo'ladi post training SFT da esa supervised yani biz o'zimiz savol va ideal javobni ham beramiz.

(20) CC BY-NC litsenziya commercial uchun ruxsat bermagan uni biznes uchun ishlata olmaymiz. Egasiga yozib ko'rish kerak agar shu data juda zarur bo'lsa.

21. Compute budget qat'iy bo'lsa Compute budget ni hisoblab GPU ham muhim uni ham hisobga olib model hajmini tanlash kerak va keyin tokens va parameters farqini Chinchilla law bo'yicha tokens parameters dan 20 barobar ko'p qilib hisob kitobini olaman.

22. Common Crawl WARC da raw data saqlash uchun HTTP response berishi kerak ekan va keyin parsing yani asosiy matn HTML dan ajratib olinadi ekan. Keyin filter va normalization yani data sifati, tili, spam ma'lumot yoki spam emasligi va xavfsizligiga qaraladi keyin deduplication keyin data split train, valida-

tion, test uchun split qilinib validation va test datalar train datoga kirib qolmaganligi chek qilinadi. va tokenization va training-ready shard.

23. Mixture weights ni empirical evaluation yani tajriba va o'lchovlar orqali tanlash yaxshi. Avval Web text, Books, code, academic va articles content kabi har bir domain u-n alohid dataset yaratib mixture taqsimot belgilab samplelarni experiment qilib eng yaxshi configuration ni katta miqyosda qayta tekshirish yaxshi.

24 Agar unique tokens tugasa multi-epoch modelni qayta train qilib generalization qobiliyatiga ~~ta'sir~~ tasir qilib overfittingga olib keladi.

model yangi bilim o'rgamasdan ko'zgan modelini qayta qayta ko'raveradi.

25. Agar quality classifier Wikipediaga o'xshash matnni afzal ko'rsa selection bais yani og'ish keltirib chiqaradi. Natijada code, forum discussions, mathematical explanations va low-resource language kabi ma'lumotlarni yo'qotishimiz mumkin.

26. Metrika o'zgarishiga o'sishiga data o'zgarishi sabab chunki orginal data b-n filtered data experiment qilinsa aniq bilinadi qolgan natijalarni o'zgartirmasdan

27. Matnni so'zma so'z qaytarsa bu yerda memorization bo'lgan

bo'ladi. Model kichkina bo'lsa bu ko'proq joy beradi chunki katta modellarda yodlashga ulgurmaydi. memorizationni aniqlash uchun memorization test yani so'zma so'z takrorlayotgan gapning faqat boshini beramiz agar takrorlasa yoki o'xshash qilib chiqarsa memorization ehtimoli yuqori. Shuning dek duplicated matn ko'p bo'lsa ham shunaqa bo'ladi chunki ko'proq ko'raveribyodlab olgan bo'ladi.

Ushbu 28, 29, 30 savollarga javobni 4-darsni boshida qilib yorib qoldiraman. Kallam tormiz bo'ldi.